

Элементы математической статистики

Математическая статистика

Математическая статистика – раздел математики, в котором изучаются и разрабатываются

методы сбора, систематизации и обработки

результатов наблюдений **массовых случайных явлений** для получения научных и практических выводов.

Происходят **многократные наблюдения** изучаемого явления.

Понятие выборки

Пусть требуется изучить случайную величину X распределённую по некоторому неизвестному закону A .

Множество значений СВ X называют **генеральной совокупностью** A .

Пусть над случайной величиной X , распределённой по закону A , проведено n экспериментов (измерений). В результате получена последовательность значений СВ X

$$x_1, \dots, x_n,$$

которая называется **выборкой** объёма n из генеральной совокупности A . Индекс показывает номер эксперимента (измерения).

Числа x_i называют **элементами выборки**.

Если провести другую серию из n экспериментов, то, как правило, получится другая выборка:

$$x'_1, \dots, x'_n.$$

Следовательно, множество всех выборок объёма n из данной генеральной совокупности можно рассматривать как систему n случайных величин

$$X_1, \dots, X_n.$$

Чтобы по выборке можно было достаточно полно судить о случайной величине X , проведение экспериментов должно быть организовано специальным образом:

- эксперименты не изменяют характера изучаемой случайной величины;
- все n экспериментов проводились в одинаковых условиях;
- эксперименты независимы друг от друга.

Это означает, что случайные величины в системе $X_1, \dots, X_n$ независимы и распределены по тому же закону A , что и изучаемая величина X .

Основные задачи математической статистики:

- организация наблюдений;
- нахождения по результатам выборочных наблюдений оценок числовых характеристик генеральной совокупности и исследование точности их приближения (выборочный метод);
- решение вопроса согласования результатов оценивания с опытными данными (проверка статистических гипотез);
- оценка влияния факторных признаков на результативный (дисперсионный анализ);
- выявление аналитической зависимости между наблюдениями факторных и результативных признаков (корреляционно-регрессионный анализ).

Факторные признаки – это независимые признаки, оказывающие влияние на другие, связанные с ними признаки.

Результативные признаки – это зависимые признаки, которые изменяются под влиянием факторных признаков.

Примеры задач математической статистики

Завод изготавливает N деталей за смену, среди них M бракованных.

Задача теории вероятностей

Какова вероятность, что в случайной выборке из n изготовленных деталей будет ровно t бракованных?

В этой задаче N и M известны.

Завод изготавливает N деталей за смену, среди них M бракованных.

Задача математической статистики

Среди n случайно выбранных изготовленных деталей оказалось ровно m бракованных. Как оценить общее число изготовленных бракованных деталей?

В этой задаче N известно, M неизвестно.

Объект движется по прямой. Движение моделируется законом:

$$x_i = \theta \cdot t_i + \varepsilon_i,$$

где t_i – момент измерения положения объекта, x_i – измеренное положение объекта в момент времени t_i , ε_i – случайная ошибка измерения, θ – неизвестная скорость объекта.

По результатам серии из n измерений можно поставить задачи:

1. **Точечное оценивание:**

найти функцию $\tilde{\theta} = f(t_1, \dots, t_n, x_1, \dots, x_n)$, значение которой близко к θ .

2. **Интервальное оценивание:**

оценить точность приближения $\tilde{\theta}$ к θ , определив $\varepsilon > 0$, для которого

$$P(|\tilde{\theta} - \theta| < \varepsilon) = \beta.$$

Значения β обычно выбирают из небольшого набора значений, близких к 1: 0,9, 0,95, 0,99.

3. **Проверка статистических гипотез:**

на основе выборки $t_1, \dots, t_n, x_1, \dots, x_n$ проверить (подтвердить или опровергнуть) предположение вида $\theta \geq \theta_0$ или $\theta = \theta_0$.

В ходе случайного эксперимента в разных условиях получены две группы данных $X_1, \dots, X_n$ и $Y_1, \dots, Y_m$.

Проверка однородности:

- Имеют ли $X_1, \dots, X_n$ и $Y_1, \dots, Y_m$ одинаковый закон распределения A ?
- Влияют ли условия эксперимента на результат?

В результате эксперимента выделено два параметра (фактора) (A, B) , принимающие конечное множество значений $a_1, \dots, a_k$ и $b_1, \dots, b_m$. После проведения серии независимых экспериментов получены количественные данные n_{ij} , $i = 1, \dots, k$, $j = 1, \dots, m$, показывающие сочетания факторов.

Проверка независимости:

Зависимы ли факторы A и B ?

Выборочный метод

Выборочный метод позволяет оценить параметры генеральной совокупности A по выборке $x_1, \dots, x_n$. Свойства (закон распределения и его параметры) генеральной совокупности A неизвестны, поэтому возникает задача их оценки по имеющейся выборке. Задача исследовать все объекты генеральной совокупности **не ставится**.

Например, рассматривая работу диспетчера, можно исследовать:

- загруженность,
- тип клиентов,
- скорость обслуживания,
- моменты поступления заявок,
- ...

Для получения верных оценок характеристик генеральной совокупности A по имеющейся выборке необходимо, чтобы выборка была **репрезентативной** (представительной).

На основании

закона больших чисел

(**предельные теоремы теории вероятностей**) можно утверждать, что выборка будет репрезентативной, если её осуществить случайно: каждый объект выборки отобран **случайно** из генеральной совокупности, если все объекты имеют одинаковую вероятность попасть в выборку.

Обработка выборки

Совокупность объектов наблюдения требуется изучить относительно некоторого количественного признака.

Простейший способ обработки выборки включает:

- построение вариационного ряда;
- вычисление размаха выборки;
- построение статистического ряда;
- построение гистограммы;
- отыскание эмпирической функции распределения;
- вычисление выборочных характеристик.

Вариационный ряд

Вариационный ряд – упорядоченная по возрастанию последовательность выборочных данных.

Если выборочные данные $x_1, x_2, \dots, x_n$ расположить в порядке неубывания от x_{min} до x_{max} , то полученная последовательность будет вариационным рядом.

Размахом выборки называется разность между наибольшим и наименьшим значениями в выборке:

$$R_x = x_{max} - x_{min}$$

Значения у различных элементов выборки $x_1, \dots, x_n$ могут совпадать. Уникальные значения элементов называют **вариантами**, то есть выборке соответствует множество вариантов

$$\{\hat{x}_1, \dots, \hat{x}_m\}, \quad m \leq n.$$

Варианта может встречаться в выборке **более одного раза**.

Пусть в выборке объёма n варианта $\hat{x}_i$ встречается n_i раз. Число n_i называется **абсолютной частотой** варианты $\hat{x}_i$, $n_1 + \dots + n_m = n$.

Отношение

$$w_i = \frac{n_i}{n}$$

называется **относительной частотой** варианты $\hat{x}_i$, $w_1 + \dots + w_m = 1$.

Статистические ряды

Последовательность пар чисел $(\hat{x}_i, n_i)$, оформленные в виде таблицы, называют **статистическим рядом абсолютных частот**.

Статистический ряд абсолютных частот

$\hat{x}_i$	$\hat{x}_1$	$\hat{x}_2$	$\dots$	$\hat{x}_m$
n_i	n_1	n_2	$\dots$	n_m

Проверка: $n_1 + n_2 + \dots + n_m = n$.

Последовательность пар чисел $(\hat{x}_i, w_i)$, оформленные в виде таблицы, называют **статистическим рядом относительных частот**.

Статистический ряд относительных частот

$\hat{x}_i$	$\hat{x}_1$	$\hat{x}_2$	$\dots$	$\hat{x}_m$
w_i	w_1	w_2	$\dots$	w_m

Проверка: $w_1 + w_2 + \dots + w_m = 1$.

При большом объёме выборки строят **группированный статистический ряд**.

Интервал значений от x_{min} до x_{max} разбивают на k равных (иногда неравных) частичных интервалов. Для каждого интервала подсчитывается значение абсолютных частот n_i^* или относительных частот w_i^* .

Вместо интервалов можно использовать значения x_i^* – середина i -го интервала.

Для определения величины интервала можно использовать **формулу Стёрджеса**:

$$h = \frac{x_{max} - x_{min}}{1 + \log_2 n}$$

Группированный статистический ряд абсолютных частот

Интервал	$[\delta_0, \delta_1)$	$[\delta_1, \delta_2)$	$\dots$	$[\delta_{k-1}, \delta_k)$
n_i^*	n_1^*	n_2^*	$\dots$	n_k^*

Проверка: $n_1^* + n_2^* + \dots + n_k^* = n$.

Группированный статистический ряд абсолютных частот

x_i^*	x_1^*	x_2^*	$\dots$	x_k^*
n_i^*	n_1^*	n_2^*	$\dots$	n_k^*

Проверка: $n_1^* + n_2^* + \dots + n_k^* = n$.

Группированный статистический ряд относительных частот

Интервал	$[\delta_0, \delta_1)$	$[\delta_1, \delta_2)$	$\dots$	$[\delta_{k-1}, \delta_k)$
w_i^*	w_1^*	w_2^*	$\dots$	w_k^*

Проверка: $w_1^* + w_2^* + \dots + w_k^* = 1$.

Группированный статистический ряд относительных частот


x_i^*	x_1^*	x_2^*	$\dots$	x_k^*
w_i^*	w_1^*	w_2^*	$\dots$	w_k^*

Проверка: $w_1^* + w_2^* + \dots + w_k^* = 1.$

Наглядно изобразить группированный ряд абсолютных частот можно с помощью ступенчатой фигуры, состоящей из прямоугольников. В основании прямоугольников лежат интервалы, а высотами являются **абсолютные частоты** n_k .


Такая ступенчатая фигура называется **гистограммой**.

Для непрерывной случайной величины гистограмма даёт некоторое представление о её плотности распределения.




Пример. Данные измерений диаметров деталей (в мм) собраны с целью установления точности изготовления. При штатном ходе производства расчётный диаметр равен 13,4 мм. При статистическом исследовании массовой продукции получена выборка объёмом $n = 200$. Постройте гистограмму.


Гистограмма при длине интервала группировки 0,05 мм.



Гистограмма при длине интервала группировки 0,01 мм.



Гистограмма при длине интервала группировки 0,2 мм.



Вывод: группировка по слишком крупным или по слишком мелким интервалам может привести к потере ясного представления о характере распределения.

При построении вероятностных характеристик **случайной величины X** используется всё множество её значений. Такие характеристики называют **теоретическими**.

Характеристики, построенные на основании **выборочных данных**, называют **эмпирическими** или **выборочными**.

Эмпирическая функция распределения

Получена выборка $x_1, \dots, x_n$.

Функция

$$F^*(x) = \frac{n_x}{n},$$

где n_x — число элементов выборки меньших x , n — объём выборки,

называется **эмпирической функцией распределения** или **функцией распределения выборки**.

Отличие теоретической функции распределения $F(x)$ от эмпирической $F^*(x)$ заключается в том, что $F(x)$ определяет **вероятность** события $X < x$, а $F^*(x)$ определяет **относительную частоту** этого же события при проведении n экспериментов.

Из закона больших чисел в форме Я. Бернулли следует, что при увеличении n эмпирическая функция распределения выборки сходится по вероятности к теоретической.

Эмпирическая функция распределения совпадает с теоретической для дискретной случайной величины, заданной рядом распределения. Поэтому эмпирическая функция распределения обладает всеми свойствами теоретической.

Числовые характеристики статистических рядов

Выборочным средним $\bar{x}$ (выборочным математическим ожиданием M_x) называется среднее арифметическое всех значений выборки:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Для статистических рядов абсолютных частот:

$$\bar{x} = \frac{\hat{x}_1 \cdot n_1 + \hat{x}_2 \cdot n_2 + \dots + \hat{x}_m \cdot n_m}{n}$$

Для статистических рядов относительных частот:

$$\bar{x} = \hat{x}_1 \cdot w_1 + \hat{x}_2 \cdot w_2 + \dots + \hat{x}_m \cdot w_m.$$

Выборочной дисперсией D_x называется среднее арифметическое квадратов отклонений значений выборки от выборочного среднего $\bar{x}$:

$$D_x = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Для статистических рядов абсолютных частот:

$$D_x = \frac{1}{n} \sum_{i=1}^m (\hat{x}_i - \bar{x})^2 \cdot n_i$$

Для статистических рядов относительных частот:

$$D_x = \sum_{i=1}^m (\hat{x}_i - \bar{x})^2 \cdot w_i$$

Выборочное среднее квадратическое отклонение выборки определяется формулой

$$\sigma_x = \sqrt{D_x}$$

При решении практических задач используется величина

$$S_x^2 = \frac{1}{n-1} \sum_{i=1}^k (x_i - \bar{x})^2 \cdot n_i$$

или

$$S_x^2 = \frac{n}{n-1} D_x,$$

которая называется **исправленной выборочной дисперсией**.

Величина

$$S_x = \sqrt{S_x^2}$$

называется **исправленным выборочным средним квадратическим отклонением**.

Для характеристики степени разброса значений выборки также используется **интерквартильный размах**.

Интерквартильный размах

$$IQR = Q_{0,75} - Q_{0,25},$$

где $Q_{0,75}$ – третий выборочный квартиль, $Q_{0,25}$ – первый выборочный квартиль.

Q_α – выборочный квантиль порядка α .

Модой M_o выборки называется варианта, имеющая наибольшую частоту.

Медианой M_e ($Q_{0,5}$) называется значение, лежащее в середине статистического ряда, если ряд имеет нечётное число членов.

Если ряд имеет чётное число членов, то медиана есть среднее арифметическое двух значений ряда, расположенных в середине ряда.

Выборочным начальным моментом k порядка ν_x^k называется среднее арифметическое всех значений выборки k -й степени:

$$\nu_x^k = \frac{1}{n} \sum_{i=1}^n x_i^k.$$

Выборочным центральным моментом k порядка μ_x^k называется среднее арифметическое k -й степени отклонений значений выборки от выборочного среднего $\bar{x}$:

$$\mu_x^k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k.$$

Выборочные характеристики совпадают с теоретическими для дискретной случайной величины, заданной рядом распределения, в котором $w_i = P(X = \hat{x}_i)$.

Предельные теоремы теории вероятностей

Математическая статистика использует математический аппарат и выводы теории вероятностей.

Связующим звеном между теорией вероятностей и математической статистикой являются предельные теоремы теории вероятностей (закон больших чисел).

Предельные теоремы условно делят на две группы:

- **Закон больших чисел (ЗБЧ)** устанавливает **статистическую устойчивость**: при большом числе испытаний статистически устойчивый параметр может быть предсказан достаточно точно. Например, средний результат перестает быть случайным и может быть предсказан с достаточной точностью.
- **Центральная предельная теорема (ЦПТ)** устанавливает условия, при которых закон распределения суммы большого числа случайных величин неограниченно **приближается к нормальному**.

Предельные теоремы теории вероятностей позволяют установить **связь между теоретическими и экспериментальными** характеристиками случайных величин при большом числе испытаний над ними.

Генеральную совокупность A считают случайной величиной X , значения которой можно получить из экспериментов, при этом закон распределения неизвестен.

Наблюдаемые в эксперименте значения можно интерпретировать как

- значения одной и той же случайной величины X , полученные в результате нескольких независимых экспериментов

или как

- наблюдаемые значения нескольких независимых в совокупности и одинаково распределённых случайных величин $X_1, X_2, \dots, X_n$.

Интерпретация 1: полагают что результаты n экспериментов являются независимыми в совокупности случайными величинами с одним и тем же законом распределения.

Поэтому в предельных теоремах рассматривают:

последовательности случайных величин $X_1, X_2, \dots, X_n$,

и случайные величины вида

$$X = X_1 + X_2 + \dots + X_n.$$

Если результаты n экспериментов рассматривать как выборку, то в первом случае СВ статистически представляет один элемент выборки.

Интерпретация 2: Если организовано несколько серий по n экспериментов в каждой, то множество всех полученных выборок можно рассматривать как систему случайных величин $X_1, X_2, \dots, X_n$.

СВ	X_1	X_2	$\dots$	X_n
Выборка 1	x_{11}	x_{12}	$\dots$	x_{1n}
Выборка 2	x_{21}	x_{22}	$\dots$	x_{2n}
Выборка $\dots$	$\dots$	$\dots$	$\dots$	$\dots$

Во втором случае для каждой случайной величины в математической статистике будет создана «своя выборка».

Сходимость по вероятности

Пусть дана последовательность случайных величин $X_1, \dots, X_n$. Говорят, что последовательность $X_1, \dots, X_n$ сходится по вероятности к числу a , если для любых чисел $\varepsilon > 0$ и $\delta > 0$ найдётся такое число $n_0(\varepsilon, \delta)$, зависящее от ε и δ , что для всех $n > n_0$ выполняется неравенство

$$P(|X_n - a| < \varepsilon) > 1 - \delta. \quad (1)$$

Практически достоверное событие.

Подчеркнём, что a – величина не случайная.

$$P(|X_n - a| > \varepsilon) < \delta. \quad (2)$$

Практически невозможное событие.

Сходимость по вероятности обозначают:

$$X_n \xrightarrow[n \rightarrow \infty]{P} a$$

Неравенство Чебышёва

Теорема. Если СВ X имеет мат. ожидание $M[X]$ и дисперсию $D[X]$, то для любого $\varepsilon > 0$ справедливо неравенство Чебышёва

$$P(|X - M[X]| \geq \varepsilon) \leq \frac{D[X]}{\varepsilon^2} \quad (3)$$

Неравенство Чебышёва даёт только верхнюю границу вероятности заданного отклонения.

Границу нельзя превзойти ни при каком законе распределения.

Неравенство Чебышёва можно записать в другой форме:

$$P(|X - M[X]| < \varepsilon) \geq 1 - \frac{D[X]}{\varepsilon^2} \quad (4)$$



Какая граница задана?

Неравенство Чебышёва можно использовать:

1. для грубой оценки вероятностей событий, связанных со СВ, распределение которой неизвестно;
2. доказательства ряда теорем ЗБЧ.

Пример. Оценить с помощью неравенства Чебышёва вероятность того, что отклонение СВ X от своего мат. ожидания будет больше $3\sigma_X$.

С помощью неравенства Чебышёва получаем оценку:

$$P(|X - M[X]| > 3\sigma_X) \leq \frac{\sigma_X^2}{(3\sigma_X)^2} = \frac{1}{9} = 0,1).$$

Для СВ $X \sim N(a, \sigma^2)$ из «правила трёх сигм»:

$$P(|X - a| \geq 3\sigma_X) = 2\Phi\left(\frac{3\sigma_X}{\sigma_X}\right) \approx 0,0027$$

Пример. Оценить с помощью неравенства Чебышёва вероятность того, что отклонение СВ X от своего мат. ожидания будет меньше $3\sigma_X$.

С помощью неравенства Чебышёва получаем оценку:

$$P(|X - M[X]| < 3\sigma_X) \geq 1 - \frac{\sigma_X^2}{(3\sigma_X)^2} = 1 - \frac{1}{9} = \frac{8}{9} = 0,8).$$

Для СВ $X \sim N(a, \sigma^2)$ из «правила трёх сигм»:

$$P(|X - a| \leq 3\sigma_X) = 2\Phi\left(\frac{3\sigma_X}{\sigma_X}\right) \approx 0,9973$$

Закон больших чисел в форме Чебышёва

Теорема Чебышёва. Если случайные величины $X_1, \dots, X_n$ попарно независимы и одинаково распределены с конечной дисперсией $D[X_i]$, $i = 1, \dots, n$, то для любого $\varepsilon > 0$

$$P \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n M[X_i] \right| < \varepsilon \right) \geq 1 - \delta, \quad (5)$$

т.е. среднее арифметическое этих случайных величин сходится по вероятности к среднему арифметическому их математических ожиданий:

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{P} \frac{1}{n} \sum_{i=1}^n M[X_i] \quad (6)$$

Следствие. Если случайные величины $X_1, \dots, X_n$ независимы и одинаково распределены, $M[X_i] = a$, $D[X_i] = \sigma^2$, то для любого $\varepsilon > 0$

$$P \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - a \right| < \varepsilon \right) \geq 1 - \delta, \quad (7)$$

то есть среднее арифметическое случайных величин сходится по вероятности к математическому ожиданию a :

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{P} a.$$

Следствие из теоремы Чебышёва обосновывает «принцип среднего арифметического СВ X_i », постоянно используемый на практике.

Пусть произведено n независимых измерений некоторой величины, истинное значение a которой неизвестно. Результат каждого измерения есть случайная величина X_i . Согласно следствию, в качестве приближенного значения величины a можно взять среднее арифметическое результатов измерений:

$$a \approx \frac{1}{n} \sum_{i=1}^n X_i.$$

Равенство тем точнее, чем больше n .

На теореме Чебышёва основан также широко применяемый в статистике **выборочный метод**, суть которого в том, что о качестве большого количества однородного материала можно судить по небольшой его пробе.

Теорема Чебышёва подтверждает связь между случайностью и необходимостью: среднее значение **случайной величины**

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

практически не отличается от **неслучайной величины**

$$\frac{1}{n} \sum_{i=1}^n M[X_i].$$

Закон больших чисел в форме Я. Бернулли

Теорема Я. Бернулли. Если вероятность появления события A при одном испытании равна p , число наступления этого события при n независимых испытаниях равно n_A , то для любого числа $\varepsilon > 0$ имеет место равенство:

$$P\left(\left|\frac{n_A}{n} - p\right| < \varepsilon\right) \geq 1 - \delta, \quad (8)$$

т.е. относительная частота $P^*(A)$ события A сходится по вероятности к вероятности p события A :

$$P^*(A) \xrightarrow[n \rightarrow \infty]{P} P(A).$$