

Оценка неизвестных параметров распределения

Статистическое оценивание

Статистическое оценивание – один из основных разделов математической статистики, посвящённый оцениванию по случайным наблюдениям тех или иных характеристик их распределения.

Оценки:

- точечные;
- интервальные.

Пусть изучается СВ X с законом распределения A , зависящим от одного или нескольких параметров.

Например, параметр λ в распределении Пуассона или параметры a и σ для нормального распределения.

Требуется по выборке $x_1, x_2, \dots, x_n$, полученной в результате n экспериментов (наблюдений) оценить неизвестный параметр θ .

Статистической оценкой $\tilde{\theta}$ параметра θ называют значение некоторой функции выборочных значений случайной величины, т.е.

$$\tilde{\theta} = S(x_1, x_2, \dots, x_n).$$

Оценка $\tilde{\theta}$ – приближенное значение, зависящее от данных выборки.

Функцию $S(x_1, x_2, \dots, x_n)$ результатов наблюдений (функцию выборки) называют **статистикой**.

Оценка $\tilde{\theta}$ параметра θ – это статистика, которая в определённом смысле близка к истинному значению θ .

Статистика, используемая в качестве приближённого значения неизвестного параметра генеральной совокупности A , называется её **точечной оценкой**.

То есть точечная оценка – это **число**, определяемое по выборке.

Требования к статистическим оценкам

К оценке $\tilde{\theta}$ любого параметра предъявляется ряд требований, которым она должна удовлетворять, чтобы быть «близкой» к истинному значению параметра θ .

Требования к оценке:

- состоятельность,
- несмещённость,
- эффективность.

Оценка $\tilde{\theta}$ параметра θ называется **состоятельной**, если она сходится по вероятности к оцениваемому параметру

$$\tilde{\theta} \xrightarrow[n \rightarrow \infty]{P} \theta.$$

Это означает, что с увеличением объема выборки оценка $\tilde{\theta}$ всё точнее приближается к истинному значению параметра θ .

Свойство состоятельности **обязательно** для любого правила оценивания (несостоятельные оценки не используются).

Состоятельность точечной оценки мат. ожидания $\tilde{m}$ следует из закона больших чисел в форме Чебышёва:

$$\tilde{m} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \xrightarrow[n \rightarrow \infty]{P} M[X].$$

Доказано, что состоятельной точечной оценка дисперсии $\tilde{\sigma}^2$ являются выборочная дисперсия D_x и исправленная выборочная дисперсия S_x^2 .

$$\tilde{\sigma}^2 = D_x = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

$$\tilde{\sigma}^2 = S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} D_x.$$

Оценка $\tilde{\theta}$ параметра θ называется **несмещенной**, если

$$M[\tilde{\theta}] = \theta.$$

Если $M[\tilde{\theta}] \neq \theta$, то оценка $\tilde{\theta}$ называется **смещенной**.

Если при $n \rightarrow \infty$, математическое ожидание оценки $M[\tilde{\theta}]$ сходится по вероятности к θ

$$M[\tilde{\theta}] \xrightarrow[n \rightarrow \infty]{P} \theta,$$

то оценка $\tilde{\theta}$ называется **асимптотически несмещенной**.

По свойствам мат. ожидания:

$$M[\bar{x}] = M\left[\frac{1}{n} \sum_{i=1}^n x_i\right] = \frac{1}{n} \sum_{i=1}^n M[x_i] = \frac{nM[X]}{n} = M[X],$$

оценка $\tilde{m} = \bar{x}$ **несмещённая**.

Преобразуем выражение:

$$D_x = \frac{1}{n} \sum_{i=1}^n (x_i - M[X] - \bar{x} + M[X])^2 =$$

$$= \frac{1}{n} \sum_{i=1}^n (x_i - M[X])^2 - \frac{2(\bar{x} - M[X])}{n} \sum_{i=1}^n (x_i - M[X]) + (\bar{x} - M[X])^2.$$

Так как $\sum_{i=1}^n (x_i - M[X]) = n(\bar{x} - M[X])$, то

$$D_x = \frac{1}{n} \sum_{i=1}^n (x_i - M[X])^2 - (\bar{x} - M[X])^2.$$

Проверим несмещённость оценки $\tilde{\sigma}^2 = D_x$:

$$\begin{aligned} M[D_x] &= M \left[\frac{1}{n} \sum_{i=1}^n (x_i - M[X])^2 - (\bar{x} - M[X])^2 \right] = \\ &= M \left[\frac{1}{n} \sum_{i=1}^n (x_i - M[X])^2 \right] - M [(\bar{x} - M[X])^2] = \frac{1}{n} \sum_{i=1}^n D[x_i] - D[\bar{x}] = \\ &= \frac{1}{n} \cdot n \cdot \sigma^2 - \frac{\sigma^2}{n} = \frac{n-1}{n} \cdot \sigma^2. \end{aligned}$$

В результате

$$M[D_x] = \frac{n-1}{n} \cdot \sigma^2 \neq \sigma^2,$$

следовательно, оценка $\tilde{\sigma}^2 = D_x$ является **смещённой**, но асимптотически несмещённой.

$$S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{n}{n-1} \cdot D_x.$$

$$M[S_x^2] = \frac{n}{n-1} \cdot M[D_x] = \frac{n}{n-1} \cdot \frac{n-1}{n} \cdot \sigma^2 = \sigma^2,$$

т.е. оценка $\tilde{\sigma}^2 = S_x^2$ не смещена.

В качестве одной из характеристик точности оценки вводят понятие **вариации** V оценки:

$$V = M[(\tilde{\theta} - \theta)^2].$$

Для **несмещенной** оценки вариация оценки совпадает с её дисперсией

$$V = D[\tilde{\theta}].$$

Добиться значения $V = 0$ **невозможно**.

Существует некоторое значение V_{min} , которого можно достигнуть. Величину V_{min} называют **потенциальной точностью** или **потенциальной помехоустойчивостью** оценки.

Несмещённая оценка $\tilde{\theta}$ параметра θ называется **эффективной**, если она имеет **наименьшую** дисперсию среди всех возможных несмещённых оценок параметра θ , т.е. оценка $\tilde{\theta}$ эффективна, если ее дисперсия минимальна.

Вариация (свойства дисперсии):

$$V[\bar{x}] = D[\bar{x}] = D\left[\frac{1}{n} \sum_{i=1}^n x_i\right] = \frac{1}{n^2} \sum_{i=1}^n D[x_i] = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

Доказано, что она является V_{min} , т.е. оценка $\tilde{m} = \bar{x}$ **эффективна**.

Оценка $\tilde{\sigma}^2 = S_x^2$ **асимптотически эффективна**:

$$V[S_x^2] = D[S_x^2] = \frac{2\sigma^4}{n-1}$$

Вывод. Пусть $x_1, x_2, \dots, x_n$ – выборка из генеральной совокупности A , $M[x_i] = M[X] = m$, $D[x_i] = D[X]$, $i = 1, 2, \dots, n$. Тогда выборочное среднее

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

состоятельная, несмещённая, эффективная оценка математического ожидания $M[X]$, а исправленная выборочная дисперсия

$$S_x^2 = \frac{n}{n-1} D_x$$

состоятельная, несмещённая, асимптотически эффективная оценка дисперсии $D[X]$.

Задача. Дана плотность распределения $\rho(x, \theta_1, \theta_2, \dots, \theta_m)$ с неизвестными параметрами $\theta_1, \theta_2, \dots, \theta_m$.

Требуется на основании выборки $x_1, x_2, \dots, x_n$ найти оценки

$$\tilde{\theta}_k = S_k(x_1, x_2, \dots, x_n),$$

неизвестных параметров θ_k , $k = 1, 2, \dots, m$.

Наиболее распространённые методы получения точечных оценок параметров распределения:

- метод моментов,
- метод максимального правдоподобия,
- метод наименьших квадратов.

Метод моментов

К. Пирсоном предложен метод моментов отыскания $\tilde{\theta}_k$, заключающийся в приравнении теоретических моментов выборочным

$$m_k = \nu_x^k$$

или

$$\int_{-\infty}^{+\infty} x^k \rho(x, \theta_1, \theta_2, \dots, \theta_k) dx = \frac{1}{n} \sum_{i=1}^n x_i^k.$$

В результате получится система из m уравнений с m неизвестными $\theta_1, \theta_2, \dots, \theta_m$.

Её решение принимается в качестве оценок $\tilde{\theta}_1, \tilde{\theta}_2, \dots, \tilde{\theta}_m$.

Они являются некоторыми функциями от $\nu_x^1, \nu_x^2, \dots, \nu_x^m$, а потому и от $x_1, x_2, \dots, x_n$.

Пример. Найдите оценку параметра λ показательного закона распределения методом моментов по выборке $x_1, x_2, \dots, x_n$.

Решение. В данном случае

$$\rho(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{при } x \geq 0, \\ 0, & \text{при } x < 0. \end{cases}$$

Параметр λ находим из условия

$$\lambda \int_0^{+\infty} x e^{-\lambda x} dx = \frac{1}{n} \sum_{i=1}^n x_i,$$

отсюда

$$\frac{1}{\lambda} = \frac{\sum_{i=1}^n x_i}{n},$$

следовательно,

$$\tilde{\lambda} = \frac{n}{\sum_{i=1}^n x_i}.$$

Метод максимального правдоподобия

Рассматривая выборку $x_1, x_2, \dots, x_n$ как систему независимых случайных величин, распределённых по тому же закону, что и случайная величина X , находим плотность распределения системы $x_1, x_2, \dots, x_n$:

$$\mathcal{L} = \prod_{i=1}^n \rho(x_i, \theta_1, \theta_2, \dots, \theta_m).$$

Функцию $\mathcal{L}$ называют **функцией правдоподобия**,

Величины $x_1, x_2, \dots, x_n$ считают фиксированными и рассматривают $\mathcal{L}$ как функцию от $\theta_1, \theta_2, \dots, \theta_m$.

По методу максимума правдоподобия за оценки параметров $\theta_1, \theta_2, \dots, \theta_m$ принимаются те их значения, при которых **функция правдоподобия принимает максимальное значение**, т.е. те, при которых вероятность получения данной фиксированной выборки максимальна.

Вместо функции $\mathcal{L}$ можно исследовать функцию $\ln \mathcal{L}$. Оценки являются решением системы

$$\frac{\partial \ln \mathcal{L}}{\partial \theta_k} = 0.$$

В качестве оценок применяются те решения $\tilde{\theta}_1, \tilde{\theta}_2, \dots, \tilde{\theta}_k$ этой системы, которые зависят только от $x_1, x_2, \dots, x_n$ и не зависят от оцениваемых параметров.

Пример. Найдите оценку параметра λ распределения Пуассона методом максимального правдоподобия.

Решение.

Функция вероятности распределения Пуассона:

$$P(X = m) = \frac{\lambda^m}{m!} e^{-\lambda}$$

Находим

$$\mathcal{L}(\lambda) = \ln P(X = m) = m \ln \lambda - \ln m! - \lambda$$

$$\frac{d\mathcal{L}}{d\lambda} = \frac{m}{\lambda} - 1$$

Полагая $\frac{d\mathcal{L}}{d\lambda} = 0$:

$$\frac{m}{\lambda} - 1 = 0,$$

находим оценку $\tilde{\lambda} = m$.

Так как

$$\frac{d^2\mathcal{L}}{d\lambda^2} = -\frac{m^2}{\lambda} < 0,$$

то функция правдоподобия при $\lambda = m$ принимает наибольшее значение (поскольку точка экстремума единственная).

Оценка параметров нормального распределения

Найдём оценки $\tilde{a}$ и $\tilde{\sigma}$ методом максимального правдоподобия.

Функция правдоподобия

$$\prod_{i=1}^n \rho(x_i, a, \sigma^2) = \frac{1}{(\sigma\sqrt{2\pi})^n} \exp \left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2 \right],$$

$$\mathcal{L}(x_1, x_2, \dots, x_n, a, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - a)^2 - n \ln \sigma - n \ln \sqrt{2\pi}.$$

Находим

$$\frac{\partial \mathcal{L}}{\partial a} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - a) \quad (1)$$

$$\frac{\partial \mathcal{L}}{\partial (\sigma^2)} = \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - a)^2 - \frac{n}{2\sigma^2} \quad (2)$$

Приравнивая к нулю эти частные производные и решая полученную систему уравнений относительно a и σ^2 , получаем искомые оценки.

$$\tilde{a} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \quad (3)$$

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \tilde{a})^2 \quad (4)$$

Оценки дисперсии и математического ожидания, полученные методом максимума правдоподобия, совпадают с выборочным математическим ожиданием и выборочной дисперсией, а потому состоятельны.

Интервальные оценки параметров распределения

Оценка неизвестного параметра называется **интервальной**, если она определяется двумя числами – концами интервала.

Пусть оценивается один скалярный параметр θ .

Найдем два числа, $\tilde{\theta}_l$ и $\tilde{\theta}_u$, построенных по выборке, такие, что

$$\tilde{\theta}_l < \tilde{\theta}_u,$$

для которых при заранее заданном $\gamma \in (0, 1)$ выполняется условие

$$P(\tilde{\theta}_l < \theta < \tilde{\theta}_u) \geq \gamma.$$

Интервал $(\tilde{\theta}_l, \tilde{\theta}_u)$ со случайными границами, полностью определяемый результатами экспериментов и не зависящий от неизвестных характеристик, который с заданной вероятностью γ содержит неизвестный параметр θ , называется **доверительным интервалом** для параметра θ .

Число γ – **доверительной вероятностью** или надежностью оценки.

Значения $\tilde{\theta}_l$ и $\tilde{\theta}_u$ – нижней и верхней доверительными границами.

Число $\alpha = 1 - \gamma$ называется **уровнем значимости**, оно определяет вероятность того, что оцениваемый параметр не попадёт в доверительный интервал.

На практике γ обычно выбирают заранее из небольшого набора близких к единице значений: 0,9; 0,95; 0,975; 0,99; 0,995; 0,9975; 0,999; 0,9995.

Выбор конкретного значения γ зависит от характера решаемой задачи и определяется степенью опасности тех последствий, которые может вызвать наступление событий, отнесённых этим выбором к практически невозможным.

Во многих случаях доверительный интервал минимальной длины – это интервал вида

$$(\tilde{\theta} - \varepsilon; \tilde{\theta} + \varepsilon),$$

где $\tilde{\theta}$ – точечная оценка θ , $\varepsilon > 0$.

В этом случае условие принимает вид

$$P(|\tilde{\theta} - \theta| < \varepsilon) \geq \gamma.$$

Величины ε , γ и объём выборки n являются связанными величинами: заданные значения двух величин однозначно определяют третью.

Доверительные интервалы для параметров нормального распределения

- Доверительный интервал для математического ожидания
 - при известной дисперсии;
 - при неизвестной дисперсии.
- Доверительный интервал для среднего квадратического отклонения
 - при известном мат. ожидании;
 - при неизвестном мат. ожидании.

Доверительный интервал для математического ожидания нормального распределения

Пусть получена выборка объёма n из нормального распределения $N(a, \sigma^2)$. При этом значение σ **известно**. Доверительная вероятность γ – задана. Доверительный интервал для a имеет вид:

$$\left(\tilde{a} - t \cdot \frac{\sigma}{\sqrt{n}}, \tilde{a} + t \cdot \frac{\sigma}{\sqrt{n}} \right),$$

где $\tilde{a}$ – точечная оценка мат. ожидания,

n – объём выборки,

σ – среднее квадратическое отклонение,

t – квантиль стандартного нормального распределения порядка $\frac{\gamma + 1}{2}$.

Значение t определяется по таблице нормированной функции Лапласа из равенства

$$\Phi_0(t) = \frac{\gamma}{2}.$$

Доказано, что СВ

$$X = \frac{\tilde{a} - a}{\sigma/\sqrt{n}}$$

имеет стандартное нормальное распределение $X \sim N(0, 1)$ (следствие основного следствия леммы Фишера).

Из равенства

$$\varepsilon = \frac{t \cdot \sigma}{\sqrt{n}}$$

следует:

- с возрастанием объёма выборки n число ε убывает и, значит, точность оценки увеличивается;
- увеличение надёжности γ влечет уменьшение точности оценки;
- если задать точность ε и надёжность γ , то получим равенство

$$n = \left(\frac{t \cdot \sigma}{\varepsilon} \right)^2,$$

где n – минимальный объём выборки, обеспечивающий заданную точность.

Пример. Произведено 5 независимых экспериментов над СВ $X \sim N(a, 20^2)$. Получена выборка: $x_1 = -25$, $x_2 = 34$, $x_3 = -20$, $x_4 = 10$, $x_5 = 21$. Найдите точечную оценку мат. ожидания. Постройте для него доверительный интервал с доверительной вероятностью $\gamma = 0,95$.

Найдём выборочное среднее для точечной оценки $\tilde{a}$:

$$\bar{x} = \frac{-25 + 34 - 20 + 10 + 21}{5} = 4$$

По условию $\gamma = 0,95$, значит, $\Phi_0(t) = \frac{0,95}{2} = 0,475$.

По таблице $t = 1,96$. Тогда $\varepsilon = \frac{1,96 \cdot 20}{\sqrt{5}} \approx 17,5$.

Доверительный интервал для $a = M[X]$:

$$(4 - 17,5, 4 + 17,5),$$

$$(-13,5, 21,5).$$

Пусть получена выборка объёма n из нормального распределения $N(a, \sigma^2)$. При этом значение σ **неизвестно**. Доверительная вероятность γ – задана. Доверительный интервал для a имеет вид:

$$\left(\tilde{a} - t_\gamma \cdot \frac{S_x}{\sqrt{n}}, \tilde{a} + t_\gamma \cdot \frac{S_x}{\sqrt{n}} \right)$$

Доказано, что СВ

$$T = \frac{\tilde{a} - a}{S_x / \sqrt{n}}$$

имеет распределение Стьюдента с $k = n - 1$ степенями свободы $T \sim t(k)$ (следствие основного следствия леммы Фишера).

Значение t_γ – квантиль порядка γ распределения Стьюдента с $k = n - 1$ степенями свободы, t_γ находится по таблице квантилей распределения Стьюдента.

Значение t_γ зависит от заданной доверительной вероятности γ и n .

Пример. Произведено 5 независимых экспериментов над СВ $X \sim N(a, \sigma^2)$. Получена выборка: $x_1 = -25$, $x_2 = 34$, $x_3 = -20$, $x_4 = 10$, $x_5 = 21$. Постройте для неизвестного $a = M[X]$ доверительный интервал с доверительной вероятностью $\gamma = 0,95$.

Выборочное среднее нашли в предыдущем примере: $\bar{x} = 4$. Находим значение S_x :

$$S_x^2 = \frac{1}{4}((-25 - 4)^2 \cdot 1 + (34 - 4)^2 \cdot 1 + (-20 - 4)^2 \cdot 1 + (10 - 4)^2 \cdot 1 + \\ + (21 - 4)^2 \cdot 1) = 660,5$$

$$S_x \approx 25,4.$$

По таблице для $\gamma = 0,95$ и $n = 5$ находим $t_\gamma = 2,78$.

Вычислим $t_\gamma \cdot \frac{S_x}{\sqrt{n}} = 2,78 \cdot \frac{25,7}{2,24} \approx 31,9$.

Доверительный интервал для $a = M[X]$:

$$(4 - 31,9, 4 + 31,9),$$

$$(-27,9, 35,9).$$

Доверительный интервал для среднего квадратического отклонения нормального распределения

Пусть получена выборка объёма n из нормального распределения $N(a, \sigma^2)$. При этом значение a **известно**. Доверительная вероятность γ – задана. Доверительный интервал для σ имеет вид:

$$\left(\frac{\sqrt{n} \cdot S_x}{\chi_2}; \frac{\sqrt{n} \cdot S_x}{\chi_1} \right),$$

где χ_1^2 и χ_2^2 – квантили распределения $\chi^2(k)$.

Значения χ_1^2 , χ_2^2 определяются по таблице квантилей $\chi_{\alpha,k}^2$ распределения $\chi^2(k)$.

χ_1^2 – квантиль порядка $\frac{1+\gamma}{2}$ распределения $\chi^2(n)$:

$$\chi_1^2 = \chi_{\frac{1+\gamma}{2},n}^2$$

χ_2^2 – квантиль порядка $\frac{1-\gamma}{2}$ распределения $\chi^2(n)$:

$$\chi_2^2 = \chi_{\frac{1-\gamma}{2},n}^2$$

Пусть получена выборка объёма n из нормального распределения $N(a, \sigma^2)$. При этом значение a **неизвестно**. Доверительная вероятность γ – задана. Доверительный интервал для σ имеет вид:

$$\left(\frac{\sqrt{n-1} \cdot S_x}{\chi_2}; \frac{\sqrt{n-1} \cdot S_x}{\chi_1} \right),$$

где χ_1^2 и χ_2^2 – квантили распределения $\chi^2(k)$.

χ_1^2 – квантиль порядка $\frac{1+\gamma}{2}$ распределения $\chi^2(n-1)$:

$$\chi_1^2 = \chi_{\frac{1+\gamma}{2}, n-1}^2$$

χ_2^2 – квантиль порядка $\frac{1-\gamma}{2}$ распределения $\chi^2(n-1)$:

$$\chi_2^2 = \chi_{\frac{1-\gamma}{2}, n-1}^2$$

Пример. Для оценки параметра нормально распределенной случайной величины была сделана выборка объема в 30 единиц и вычислено $S_x = 1,5$. Найти доверительный интервал, покрывающий σ с вероятностью $\gamma = 0,9$.

По таблице $\chi^2_{\alpha,k}$ находим

$$\chi_1^2 = \chi^2_{\frac{1+0,9}{2}, 30-1} = \chi^2_{0,95, 29} = 17,7,$$

$$\chi_2^2 = \chi^2_{\frac{1-0,9}{2}, 30-1} = \chi^2_{0,05, 29} = 42,6.$$

Доверительный интервал имеет вид:

$$\left(\frac{\sqrt{30-1} \cdot 1,5}{\sqrt{42,6}}; \frac{\sqrt{30-1} \cdot 1,5}{\sqrt{17,7}} \right),$$

или

$$1,238 < \sigma < 1,920.$$

Поскольку распределение $\chi^2(k)$ несимметрично, доверительный интервал для σ также будет несимметричен. При **неизвестном** a для σ можно построить симметричный доверительный интервал. Для заданного γ :

$$P(|\sigma - S_x| < \varepsilon) = \gamma$$

$$P(S_x - \varepsilon < \sigma < S_x + \varepsilon) = \gamma.$$

Преобразуем неравенство:

$$S_x \left(1 - \frac{\varepsilon}{S_x}\right) < \sigma < S_x \left(1 + \frac{\varepsilon}{S_x}\right).$$

Обозначим $\frac{\varepsilon}{S_x} = q$, тогда

$$S_x (1 - q) < \sigma < S_x (1 + q) .$$

Если $q < 1$, то доверительный интервал для σ

$$S_x (1 - q) < \sigma < S_x (1 + q) .$$

Если $q > 1$, то

$$0 < \sigma < S_x (1 + q) .$$

Значение q находится из таблицы по заданным n, γ .