

Статистическое описание двумерных случайных величин

Корреляционная таблица

Пусть исследуется двумерная случайная величина (X, Y) .

В результате измерений случайной величины (X, Y) получена выборка $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ объёма n .

Выборке $x_1, x_2, \dots, x_n$ соответствует множество вариантов $\hat{X} = \{\hat{x}_1, \hat{x}_2, \dots, \hat{x}_k\}$, $k \leq n$.

Выборке $y_1, y_2, \dots, y_n$ соответствует множество вариантов $\hat{Y} = \{\hat{y}_1, \hat{y}_2, \dots, \hat{y}_l\}$, $l \leq n$.

Для статистического описания системы СВ (X, Y) по множествам $\hat{X}$ и $\hat{Y}$ строится **корреляционная таблица** размера $(k \times l)$.

$\hat{y}_j \backslash \hat{x}_i$	$\hat{x}_1$	$\hat{x}_2$	$\cdots$	$\hat{x}_k$
$\hat{y}_1$	ν_{11}	ν_{21}	$\cdots$	ν_{k1}
$\hat{y}_2$	ν_{12}	ν_{22}	$\cdots$	ν_{k2}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
$\hat{y}_l$	ν_{1l}	ν_{2l}	$\cdots$	ν_{kl}

ν_{ij} – абсолютные частоты появления пар вариантов $(\hat{x}_i, \hat{y}_j)$, $i = 1, 2, \dots, k$,
 $j = 1, 2, \dots, l$, $n = \sum_{i=1}^k \sum_{j=1}^l \nu_{ij}$ – объём выборки.

Также рассматривают группированные корреляционные таблицы, когда (x_i^*, y_j^*) – центры интервалов соответствующих группированных статистических рядов абсолютных частот.

$y_j^* \backslash x_i^*$	x_1^*	x_2^*	$\dots$	x_m^*
y_1^*	ν_{11}^*	ν_{21}^*	$\dots$	ν_{m1}^*
y_2^*	ν_{12}^*	ν_{22}^*	$\dots$	ν_{m2}^*
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
y_q^*	ν_{1q}^*	ν_{2q}^*	$\dots$	ν_{mq}^*

ν_{ij}^* – абсолютные частоты пар (x_i, y_j) , $i = 1, 2, \dots, n$, $j = 1, 2, \dots, n$,
 n – объём выборки, попавшие в интервал с центром (x_i^*, y_j^*) .

Из корреляционной таблицы можно найти абсолютные частоты вариант:

$$\nu_{\hat{x}_i} = \sum_{j=1}^k \nu_{ij}$$

$$\nu_{\hat{y}_j} = \sum_{i=1}^l \nu_{ij}$$

Числовые характеристики

Выборочные числовые характеристики находятся:

- для выборок $x_1, x_2, \dots, x_n$ и $y_1, y_2, \dots, y_n$ с использованием формул для одномерного случая;
- по корреляционной таблице.

Выборочные математические ожидания, дисперсии СВ (X, Y) вычисляют с помощью моментов:

Выборочное среднее $\bar{x}$ (выборочное мат. ожидание m_x):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k \hat{x}_i \nu_{\hat{x}_i}$$

Выборочная дисперсия D_x :

$$D_x = \frac{1}{n} \sum_{i=1}^k (\hat{x}_i - \bar{x})^2 \nu_{\hat{x}_i}$$

Выборочное среднее $\bar{y}$ (выборочное мат. ожидание m_y):

$$\bar{y} = \frac{1}{n} \sum_{j=1}^l \hat{y}_j \nu_{\hat{y}_j}$$

Выборочная дисперсия D_y :

$$D_y = \frac{1}{n} \sum_{j=1}^l (\hat{y}_j - \bar{y})^2 \nu_{\hat{y}_j}$$

На практике для вычисления выборочных дисперсий используют упрощённые формулы:

$$D_x = \frac{1}{n} \sum_{i=1}^k \hat{x}_i^2 \nu_{\hat{x}_i} - \bar{x}^2$$

$$D_y = \frac{1}{n} \sum_{j=1}^l \hat{y}_j^2 \nu_{\hat{y}_j} - \bar{y}^2$$

Выборочные средние квадратические отклонения σ_x и σ_y :

$$\sigma_x = \sqrt{D_x}$$

$$\sigma_y = \sqrt{D_y}$$

Выборочные исправленные дисперсии S_x^2 и S_y^2 :

$$S_x^2 = \frac{1}{n-1} \sum_{i=1}^k (\hat{x}_i - \bar{x})^2 \nu_{\hat{x}_i}$$

$$S_y^2 = \frac{1}{n-1} \sum_{j=1}^l (\hat{y}_j - \bar{y})^2 \nu_{\hat{y}_j}$$

На практике для вычисления исправленных выборочных дисперсий используют упрощённые формулы:

$$S_x^2 = \frac{1}{n-1} \sum_{i=1}^k \hat{x}_i^2 \nu_{\hat{x}_i} - \bar{x}^2$$

$$S_y^2 = \frac{1}{n-1} \sum_{j=1}^l \hat{y}_j^2 \nu_{\hat{y}_j} - \bar{y}^2$$

Выборочные исправленные средние квадратические отклонения S_x и S_y :

$$S_x = \sqrt{S_x^2}$$

$$S_y = \sqrt{S_y^2}$$

Доказано, что все приведённые статистики являются состоятельными оценками соответствующих параметров генеральной совокупности A (случайной величины (X, Y)).

Выборочные характеристики связи двух случайных величин

Выборочная ковариация $COV(\hat{X}, \hat{Y})$ вычисляется по формуле:

$$COV(\hat{X}, \hat{Y}) = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^l \hat{x}_i \hat{y}_j \nu_{ij} - \bar{x} \bar{y}$$

Выборочный коэффициент корреляции r_{xy} (коэффициент корреляции Пирсона) вычисляется по формуле:

$$r_{xy} = \frac{COV(\hat{X}, \hat{Y})}{\sigma_x \sigma_y}$$

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x}_i)(y_i - \bar{y}_i)}{(n-1)S_x S_y}$$

$$r_{xy} = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}_i \bar{y}_i}{n\sigma_x \sigma_y}$$

Выборочное уравнение прямой регрессии Y на X .

$$y - \bar{y} = r_{xy} \cdot \frac{\sigma_y}{\sigma_x} \cdot (x - \bar{x})$$

Выборочная функция линейной регрессии Y на X :

$$g(x) = r_{xy} \cdot \frac{\sigma_y}{\sigma_x} \cdot (x - \bar{x}) + \bar{y}$$

Выборочное уравнение прямой регрессии X на Y :


$$x - \bar{x} = r_{xy} \cdot \frac{\sigma_x}{\sigma_y} \cdot (y - \bar{y})$$

Выборочная функция линейной регрессии X на Y :

$$g(y) = r_{xy} \cdot \frac{\sigma_x}{\sigma_y} \cdot (y - \bar{y}) + \bar{x}$$

Выборочные прямые регрессии проходят через точку $(\bar{x}, \bar{y})$.

Поскольку $|r_{xy}| \leq 1$, угол наклона прямой регрессии находится в интервале $(-45^\circ, 45^\circ)$.




Выборочную дисперсию D_y можно представить как


$$D_y = D_{res_y} - D_{reg_y},$$


где D_{res_y} – дисперсия выборочных данных относительно регрессии Y на X , D_{reg_y} – дисперсия регрессии Y на X .

$$D_{res_y} = \frac{1}{n} \sum_{i=1}^n (y_i - g(x_i))^2$$

$$D_{reg_y} = \frac{1}{n} \sum_{i=1}^n (g(x_i) - y_i)^2$$

Графическое представление D_y 

Графическое представление D_{res_y} 

Графическое представление D_{reg_y} 

Для определения степени «качества» линейной регрессии вводят **коэффициент детерминации** R_{xy} , который показывает степень соответствия линейной регрессионной выборке.

$$R_{xy} = r_{xy}^2, \quad 0 \leq R_{xy} \leq 1.$$

Пример. Дана корреляционная таблица системы (X, Y) . Найдите выборочные уравнения прямых регрессии Y на X и X на Y .

$Y \backslash X$	2	4	6	8	10
1	5	4	2	0	0
2	0	6	3	3	0
3	0	0	1	2	3
5	0	0	0	0	1

Количество пар $n = 30$.

Вычислим выборочные средние $\bar{x}$ и $\bar{y}$:

$$\bar{x} = \frac{2 \cdot 5 + 4 \cdot (4 + 6) + 6 \cdot (2 + 3 + 1) + 8 \cdot (3 + 2) + 10 \cdot (3 + 1)}{30} \approx 5,53$$

$$\bar{y} = \frac{1 \cdot (5 + 4 + 2) + 2 \cdot (6 + 3 + 3) + 3 \cdot (1 + 2 + 3) + 5 \cdot 1}{30} \approx 1,93$$

Вычислим дисперсии D_x и D_y :

$$\begin{aligned} D_x &= \frac{2^2 \cdot 5 + 4^2 \cdot (4 + 6) + 6^2 \cdot (2 + 3 + 1) + 8^2 \cdot (3 + 2) + 10^2 \cdot (3 + 1)}{30} - 5,53^2 = \\ &= 37,2 - 30,58 \approx 6,58 \end{aligned}$$

$$\begin{aligned} D_y &= \frac{1^2 \cdot (5 + 4 + 2) + 2^2 \cdot (6 + 3 + 3) + 3^2 \cdot (1 + 2 + 3) + 5^2 \cdot 1}{30} - 1,93^2 = \\ &= 4,6 - 3,72 \approx 0,86 \end{aligned}$$

Вычислим средние квадратические отклонения σ_x и σ_y :

$$\sigma_x = \sqrt{D_x} = \sqrt{6,62} \approx 2,57$$

$$\sigma_y = \sqrt{D_y} = \sqrt{0,88} \approx 0,93$$

Найдём ковариацию $COV(\hat{X}, \hat{Y})$:

$$\sum_{i=1}^l \sum_{j=1}^q \hat{x}_i \hat{y}_j \nu_{ij} = 2 \cdot 1 \cdot 5 + 4 \cdot 1 \cdot 4 + 6 \cdot 1 \cdot 2 + 4 \cdot 2 \cdot 6 + 6 \cdot 2 \cdot 3 + \\ + 8 \cdot 2 \cdot 3 + 6 \cdot 3 \cdot 1 + 8 \cdot 3 \cdot 2 + 10 \cdot 3 \cdot 3 + 10 \cdot 5 \cdot 1 = 376$$

$$COV(\hat{X}, \hat{Y}) = \frac{1}{n} \sum_{i=1}^l \sum_{j=1}^q \hat{x}_i \hat{y}_j \nu_{ij} - \bar{x} \cdot \bar{y} = \frac{376}{30} - 5,53 \cdot 1,93 \approx 12,53 - 10,67 \approx 1,86$$

Вычислим коэффициент корреляции r_{xy} :

$$r_{xy} = \frac{1,86}{2,57 \cdot 0,93} \approx \frac{1,86}{2,39} \approx 0,77$$

Уравнение прямой регрессии Y на X :

$$y = 0,77 \cdot \frac{0,93}{2,57} \cdot (x - 5,53) + 1,93 = 0,279x - 1,541 + 1,93 = 0,279x + 0,39$$

Уравнение прямой регрессии X на Y :

$$x = 0,77 \cdot \frac{2,57}{0,93} \cdot (y - 1,93) + 5,53 = 2,128y - 4,106 + 5,53 = 2,128y + 1,418$$


Итого:

Уравнение прямой регрессии Y на X :

$$y = 0,279x + 0,39$$

Уравнение прямой регрессии X на Y :

$$x = 2,128y + 1,418$$



Вычислим коэффициент детерминации R_{xy} :

$$R_{xy} = r_{xy}^2 = 0,77^2 = 0,5929.$$

Так как коэффициент детерминации не близок к 1, степень соответствия линейной регрессии выборочным данным невысокая.